

DB개선 — SafeWork AI 데이터 설계 문서

ML팀(신찬우) -> DB팀(강주호) 전달 / output/ 폴더 내 SQL 파일 3개

전달 파일 목록

파일명	내용	크기
checklist_item_insert.sql	법령 2547개 + 체크리스트 질문 835개	~1.9 MB
ml_encoding_map_create_insert.sql	ML 인코딩 기준표 (신규 테이블)	소용량
ml_training_data_create_insert.sql	ML 학습 데이터 126만 행 (신규 테이블)	~627 MB

checklist_item_insert.sql — 법령 + 체크리스트

법령 데이터가 먼저, 체크리스트가 법령을 참조하는 구조라 순서 고정.

[1] law_article 테이블 — 법령 조항 2547개

법령명	조항 수
산업안전보건법	
산업안전보건법 시행령	
산업안전보건법 시행규칙	
산업안전보건기준에 관한 규칙	합계 2547개
중대재해 처벌 등에 관한 법률	

[2] checklist_item 테이블 — 체크리스트 질문 835개

컬럼	내용	예시
item_code	항목 식별 코드	SIF-CON-0001 (건설업), SIF-MFG-0001 (제조업)
category	작업 종류	굴착 작업, 가공 설비를 이용한 작업
question	체크리스트 질문	굴착면의 기울기가 안전 기준을 준수하고 있는가?
description	관련 실제 산재 사고 요약	[무너짐] 2018년 OO공사 굴착사면 붕괴...
target_industry	업종	건설업 / 제조업
risk_weight	가중치 (지지 사고 건수)	7 (실제 7건 산재 기반)
law_ref	관련 법령 article_id 목록	"1489,1486"

law_ref 연결 구조

실제 산재 사고 기반 체크리스트 질문마다 AI(임베딩 유사도 + LLM)가 관련 법령 매핑.

```
law_ref = "1489,1486"
→ law_article 테이블에서 article_id 1489, 1486 조회하면 해당 법령 조항 전문 확인 가능
```

ML 인코딩 + 학습 데이터 설계

ml_encoding_map_create_insert.sql — 인코딩 기준표 (신규 테이블)

ML 모델이 한글 값을 정수로 변환하는 기준. 모델 재사용 시 동일 기준 적용 필수.

컬럼	내용	예시
feature_name	피쳐 이름	연령, 규모, 발생형태
original_val	원본 한글 값	40세~44세, 5~9인, 떨어짐
encoded_val	정수 인코딩 값	5, 1, 6
enc_type	인코딩 방식	ordinal(순서형) / label(명목형)

피쳐	방식	클래스 수
규모	ordinal	9개
연령	ordinal	10개
근무기간	ordinal	8개
건설공사금액	ordinal	8개 (건설업 전용)
발생형태	label	23개
질병종류	label	9개
세부질병종류	label	32개
종업종	label	44개 (82개 원본명 정규화)

* 성별·지역·산업은 원핫 인코딩 (컬럼명 규칙: 성별_남, 지역_경기 등) — 별도 테이블 없음

ml_training_data_create_insert.sql — 학습 데이터 (신규 테이블)

인코딩까지 완료된 ML 최종 학습 데이터. 기존 ai_safework_full.sql에 없는 신규 테이블.

컬럼	내용	예시
dataset_type	데이터 종류	accident(발생형태 예측) / disease(질병종류 예측)
industry	업종	건설업, 제조업, 광업 등
year	연도	2017 ~ 2025
features	인코딩된 피쳐 (JSON)	{"규모_enc": 1, "연령_enc": 5, ...}
target_enc	예측 대상값 (정수)	6 (발생형태 떨어짐에 해당)
target_col	예측 대상 컬럼명	accident_type / disease_type

업종	발생형태 예측	질병종류 예측
건설업	267,808행	41,688행
제조업	272,493행	60,941행
광업	24,824행	23,545행
기타의사업	404,326행	43,488행
운수·창고·통신업	95,070행	7,194행
소규모 통합	20,965행	1,880행
합계	1,085,486행	178,736행

[주의] 파일 크기 약 627MB — DB 서버 여유 공간 확인 후 적재 권장

전체 데이터 흐름

실제 산재 사고 데이터 (SIF 건설업 2,574건 + 제조업 1,858건)

↓ AI 분류 + LLM 체크리스트 생성

체크리스트 질문 (공종/작업 x 발생형태 조합)

↓ 임베딩 유사도(sentence-transformers) + LLM 법령 매핑

checklist_item_insert.sql

├── law_article : 2547개 법령 조항

└── checklist_item : 835개 질문 + law_ref (법령 article_id 참조)

KOSHA 마이크로데이터 (2017~2025, 약 109만 행)

↓ 전처리 + 인코딩 (kosha_encodings.py 기준)

ml_training_data_create_insert.sql : 126만 행 (발생형태 + 질병종류)

ml_encoding_map_create_insert.sql : 인코딩 기준표 151개

DB팀 참고사항

항목	내용
체크리스트 코드 충돌	SIF- prefix 사용. 기존 항목(SIF- 아닌 것) 건드리지 않음
법령 article_id	기존 ai_safework_full.sql과 동일한 ID. 변경 시 law_ref 참조 전체 깨짐
ml_training_data 재실행	DELETE 후 전체 INSERT 구조 — 재실행 시 덮어쓰기
신규 테이블	ml_encoding_map, ml_training_data 2개가 ai_safework_full.sql에 없는 신규

FastAPI 연동 참고 (law_ref 활용)

```
# checklist_item.law_ref = "1489,1486"

law_ids = [int(x) for x in item.law_ref.split(",") if x]

-- law_article 조회 예시
SELECT * FROM law_article WHERE article_id = ANY(ARRAY[1489, 1486]);
```