

predict.py 사용 가이드

LightGBM 기반 산재 사고 유형 확률 Top-K 예측 모듈

학습된 LightGBM 모델로 산재 사고의 발생형태 · 재해정도 · 질병종류 · 세부질병종류 확률을 Top-K로 반환하는 예측 모듈.

입력 파라미터

파라미터	타입	필수	설명
대업종	str	필수	아래 허용값 참고
중업종	str	필수	KOSHA 원본 문자열 (내부 자동 정규화)
성별	str	필수	남 / 여
연령	str	필수	예: 40세~44세
근무기간	str	필수	예: 1~2년 미만
규모	str	필수	예: 5~9인
지역	str	필수	예: 경기
건설공사금액	str None	선택	건설업 전용. 생략 시 해당없음 처리
년도	int	선택	예측 기준 연도 (기본값: 2024)
top_k	int	선택	반환할 후보 수 (기본값: 3)

반환값 (dict)

키	타입	설명
발생형태	list[tuple[str, float]] None	사고 유형 Top-K (23개 클래스)
재해정도	list[tuple[str, float]] None	재해 심각도 Top-K (8개 클래스)
질병종류	list[tuple[str, float]] None	업무상질병 유형 Top-K (7~9개 클래스)
세부질병종류	list[tuple[str, float]] None	세부 질병 분류 Top-K (21~32개 클래스)

※ 각 항목은 (라벨, 확률) 튜플 리스트로 확률 내림차순 정렬. 해당 모델 파일 없으면 None 반환.

허용값 — 대업종

- 건설업
- 광업
- 기타의사업
- 운수·창고·통신업
- 제조업
- 농업
- 어업
- 임업
- 전기·가스·증기·수도사업
- 금융및보험업

* 농업·어업·임업·전기·가스·증기·수도사업·금융및보험업 → 소규모 통합 모델 적용

허용값 — 연령

- ~19세
- 20세~24세
- 25세~29세
- 30세~34세
- 35세~39세
- 40세~44세
- 45세~49세
- 50세~54세
- 55세~59세
- 60세~64세
- 65세~

허용값 — 규모

- 1인
- 2~4인
- 5~9인
- 10~29인
- 30~49인
- 50~99인
- 100~299인
- 300인 이상

허용값 — 근무기간

- 1개월 미만
- 1~3개월 미만
- 3~6개월 미만
- 6개월~1년 미만
- 1~2년 미만
- 2~3년 미만
- 3~4년 미만
- 4~5년 미만
- 5년 이상

허용값 — 지역

- 서울
- 부산
- 대구
- 인천
- 광주
- 대전
- 울산
- 경기
- 강원
- 충남
- 충북
- 전남
- 전북
- 경남
- 경북
- 제주

허용값 — 건설공사금액 (건설업 전용)

- 해당없음
- 3억 미만
- 3억~5억 미만
- 5억~10억 미만
- 10억~30억 미만
- 30억~50억 미만
- 50억~100억 미만
- 100억~300억 미만
- 300억 이상

1. Python import 방식

```
from predict import predict

result = predict(
    대업종 = '제조업',
    종업종 = '기계기구·금속·비금속광물제품제조업',
    성별 = '남',
    연령 = '40세~44세',
    근무기간 = '1~2년 미만',
    규모 = '5~9인',
    지역 = '경기',
    top_k = 3,
)

print(result['발생형태'])
# [('끼임', 0.2878), ('물체에맞음', 0.1225), ('절단베임찢림', 0.1152)]
```

2. 터미널 CLI 방식

```
python predict.py ₩
--대업종 제조업 ₩
--종업종 "기계기구·금속·비금속광물제품제조업" ₩
--성별 남 ₩
--연령 "40세~44세" ₩
--근무기간 "1~2년 미만" ₩
--규모 "5~9인" ₩
--지역 경기 ₩
--top_k 3
```

건설업 추가 예시 (건설공사금액 포함):

```
python predict.py ₩
--대업종 건설업 --종업종 건축공사업 --성별 남 ₩
--연령 "50세~54세" --근무기간 "1개월 미만" ₩
--규모 "5~9인" --지역 서울 ₩
--건설공사금액 "5억~10억 미만"
```

3. 출력 예시

발생형태:	
끼임	0.2878
물체에맞음	0.1225
절단베임찢림	0.1152
재해정도:	
91~180일	0.4044
29~90일	0.3414
6개월 이상	0.1755
질병종류:	
요통	0.4936
신체부담작업	0.3628
뇌.심혈관질환	0.0878
세부질병종류:	
신체부담작업	0.3568
사고성 요통	0.3044
비사고성 요통	0.1887

내부 동작 흐름

입력값

└─ 대업종 판별 → 모델 파일 suffix 결정

└─ 소규모 (농업/어업/임업/전기가스/금융) → 소규모통합 모델

└─ 대규모 (건설/광업/기타/운수/제조) → 업종별 개별 모델

└─ 종업종 정규화 (SUBJOB_NORM: 82개 원본 → 44개 통합)

└─ 전체 피쳐 인코딩 (_build_row)

└─ 규모 / 연령 / 근무기간 / 종업종 → 순서형 정수 인코딩

└─ 성별 / 지역 → 원핫 인코딩

└─ 건설공사금액 → 건설업 전용 순서형 인코딩

└─ 모델별 predict → softmax 확률 배열

└─ Top-K 추출 → 역매핑 (enc → 한글 라벨)

└─ dict 반환

모델 파일 정보

경로: ML모델/models/{태스크명}_{업종명}.txt | 총 30개 (5 태스크 × 6 업종)

태스크명	예측 대상	클래스 수	모델 수
발생형태	사고 유형 분류	23	6
재해정도_발생형태기반	재해 심각도 (사고)	8	6
질병종류	업무상질병 유형	7~9	6
세부질병종류	세부 질병 분류	21~32	6
재해정도_질병기반	재해 심각도 (질병)	8	6

업종별 피쳐 구성

업종	피쳐 수	피쳐 목록
건설업	22	통계기준년월, 규모/연령/근무기간/종업종_enc, 건설공사금액_enc, 성별_남, 지역×15
대규모 5개	21	통계기준년월, 규모/연령/근무기간/종업종_enc, 성별_남, 지역×15
소규모 통합	25	통계기준년월, 산업원핫×4, 규모/연령/근무기간/종업종_enc, 성별_남, 지역×15

주의사항

- ① predict.py는 ML모델/ 폴더 기준으로 실행하거나 sys.path에 해당 경로가 포함되어 있어야 함.
- ② 종업종은 KOSHA 원본 문자열을 그대로 넣으면 내부에서 자동 정규화 처리됨.
- ③ 질병종류 / 세부질병종류는 업무상질병 데이터로만 학습된 모델 —

사고성 재해에 적용 시 참고용으로만 활용할 것.
- ④ 확률값은 모델 예측 확률이므로 전체 합이 1.0이며,

Top-K는 그 중 상위 K개만 추출한 것 (나머지 확률 합 = 1 - 표시된 합).