

사고확률추정기 — 베이지 정리 기반 산재 발생 위험도 추정 모듈

역할

근로자의 특성(산업, 연령, 성별, 지역, 사업장 규모)을 입력하면 어떤 유형의 사고가 얼마나 높은 확률로 발생하는지 를 순위별로 반환한다.

원리

왜 단순 KOSHA 비율이 아닌가?

KOSHA 마이크로데이터는 사고가 이미 난 사람들의 기록만 있다.
예: "건설업 40대 남성이 산재가 많다" → 단순히 건설업에 40대 남성이 많아서일 수도 있음.
이 편향을 보정하기 위해 베이지 정리를 적용한다.

수식

$$P(\text{발생 형태} = k, \text{사고} \mid F) \propto \frac{P(F, k \mid \text{사고}) \times P(\text{사고})}{P(F)}$$

항	의미	데이터 파일
$P(F, k \mid \text{사고})$	산재 발생자 중 특성 F이고 발생형태가 k 인 비율	P_FL_given_accident.csv
$P(\text{사고})$	전체 근로자 대비 전체 재해자 수 (상수, 전 업종 합산)	P_업종 사고_재해율.csv
$P(F)$	전체 근로자 중 특성 F인 비율 (IPF 추정)	P_F_joint.csv

입력 피처

`predict()` 메서드에 아래 5개 인자를 전달한다.

1. 산업 — 업종 (str)

값
'건설업'
'광업'
'금융및보험업'
'기타의사업'
'농업'
'어업'
'운수·창고·통신업'
'임업'
'전기·가스·증기·수도사업'
'제조업'

2. 연령 — 연령대 (str)

KOSHA 원본의 세분화된 연령을 아래 5개 표준 그룹으로 입력한다.

입력값	해당 연령
'20~29세'	18세 미만 + 18~24세 + 25~29세
'30~39세'	30~34세 + 35~39세
'40~49세'	40~44세 + 45~49세
'50~59세'	50~54세 + 55~59세
'60세 이상'	60세 이상

3. 성별 — 성별 (str)

값
'남'

값

'여'

4. 시도 — 지역 (str)

값 (16개 시도)

'강원', '경기', '경남', '경북', '광주', '대구', '대전',
'부산'

'서울', '울산', '인천', '전남', '전북', '제주', '충남',
'충북'

세종시는 KOSHA 마이크로데이터에 산재 케이스 없음 → 지원 안 됨

5. 규모 — 사업장 규모 (str)

값

종업원 수

'5인 미만'

~4명

'5~9인'

5~9명

'10~19인'

10~19명

'20~49인'

20~49명

'50~99인'

50~99명

'100~299인'

100~299명

'300~499인'

300~499명

'500~999인'

500~999명

'1,000인 이상'

1,000명 이상

출력

pandas.DataFrame 반환. 컬럼:

컬럼

타입

설명

발생 형태

str

사고 유형 (넘어짐, 떨어짐, 끼임 등 최대 23개)

컬럼	타입	설명
P_risk	float	해당 발생형태의 사고 위험도 점수
순위	int	위험도 높은 순 (1 = 가장 위험)

P_risk 는 절대 확률이 아닌 **상대적 위험도 점수**이며, 특성 조합 간 비교에 사용한다.

사용 예시

```
from risk_estimator import RiskEstimator

est = RiskEstimator() # 데이터 한 번만 로드

result = est.predict(
    산업='건설업',
    연령='40~49세',
    성별='남',
    시도='경기',
    규모='50~99인',
)

print(result)
#      발생형태   P_risk  순위
#      떨어짐  0.007101    1
#      물체에맞음 0.003842    2
#      넘어짐  0.003705    3
#      끼임  0.002881    4
#      부딪힘  0.002401    5
#      절단베임찔림 0.001749    6
#      업무상질병 0.001235    7
#      깔림.뒤집힘 0.000995    8
#      불균형및무리한동작 0.000960    9
#      무너짐 0.000446   10
#      ...

# 상위 3개만 보기
print(result.head(3))

# 1위 사고 유형
top = result.iloc[0]
print(f"가장 위험한 사고: {top['발생형태']} (위험도 {top['P_risk']:.4f})")
```

의존 데이터 (체인룰 데이터/)

모듈 실행 전 체인룰 데이터 / 폴더에 아래 3개 파일이 있어야 한다.

파일	생성 스크립트
P_FL_given_accident.csv	compute_P_F_given_accident.py
P_F_joint.csv	ipf.py
P_업종 사고_재해율.csv	kosis_finalize.py

파일 구조

```
사고확률추정기/  
├─ risk_estimator.py  모듈  본체  
└─ README.md        이  파일
```