

피처-타겟 연관성 검정

카이제곱 + Cramér's V 분석 보고서

분석 목적

ML 모델 성능이 전반적으로 낮게 나온 원인을 규명하고,
각 피처가 타겟 변수와 실제로 얼마나 연관되어 있는지 통계적으로 검증.

단순 p-value는 샘플 수(약 108만 행)가 크면 전부 유의하게 나오므로,
Cramér's V (효과 크기)를 주요 지표로 사용.

검정 방법

① 카이제곱 독립성 검정

두 범주형 변수가 서로 독립인지 검정 (관측 빈도 vs 기대 빈도 비교)

② Cramér's V (효과 크기)

카이제곱은 n에 비례해 커지므로, n과 카테고리 수로 정규화 → 0~1 스케일로 비교 가능.

$V = \sqrt{\chi^2 / (n \times \min(r-1, c-1))}$ r: 피처 카테고리 수 | c: 타겟 카테고리 수

V 범위	연관 강도
0.00 ~ 0.10	거의 무관계
0.10 ~ 0.20	약한 연관
0.20 ~ 0.30	중간 연관
0.30 이상	강한 연관

데이터 설계

구분	조건	행수
전체	분류불능 제외	1,089,169
업무상질병	발생형태 == 업무상질병	179,570
건설업	대업종 == 건설업	271,176
건설업+질병	건설업 중 업무상질병	42,371

피처 및 타겟

피처: 대업종 · 년도 · 규모 · 성별 · 연령 · 근무기간 · 지역 · 건설공사금액(건설업 한정)

타겟: 발생형태(전체) · 재해정도(전체) · 질병종류(업무상질병) · 세부질병종류(업무상질병)


Cramér's V 전체 결과 (전 조합 p < 0.001 ***)

피처	발생형태	재해정도	질병종류	세부질병종류	비고
성별	0.346 ★	0.139	0.271	0.330 ★	전체
대업종	0.251	0.170	0.242	0.250	전체
근무기간	0.150	0.109	0.162	0.172	전체
연령	0.122	0.115	0.187	0.198	전체
규모	0.117	0.059	0.094	0.103	전체
건설공사금액	0.107	0.036	0.038	0.058	건설업만
지역	0.071	0.097	0.172	0.135	전체
년도	0.052	0.032	0.079	0.102	전체

피처별 해석

- ▶ **성별 V = 0.346 — 가장 강함**
 - 성별 자체보다 직종 분리(occupational segregation)를 반영.
 - 남성: 건설·제조·중장비 → 떨어짐·끼임·물체에 맞음 집중
 - 여성: 서비스·의료·사무 → 넘어짐·업무상질병·불균형동작 집중
 - 데이터에 실제 직종 피처가 없어 성별이 그 역할을 흡수.
- ▶ **대업종 V = 0.251**
 - 업종마다 작업환경이 달라 사고 패턴 차이 존재.
 - 성별보다 낮은 이유: 업종 내부에서도 다양한 사고 유형이 혼재.
- ▶ **근무기간 V = 0.150 / 연령 V = 0.122**
 - 신입 vs 베테랑, 연령대별 사고 패턴 차이 존재하나 설명력은 제한적.
- ▶ **규모 V = 0.117 / 건설공사금액 V = 0.107**
 - 소규모 사업장 안전 관리 부족, 공사 규모별 작업 유형 차이 반영.
- ▶ **지역 V = 0.071 / 년도 V = 0.052 — 가장 약함**
 - 지역은 지역별 주요 업종 분포를 간접 반영하는 수준.
 - 년도: 시간이 지나도 사고 패턴이 거의 변하지 않음 → 정상(stationary).

Cramér's V 히트맵



결론

① ML 성능 저하의 통계적 근거

모든 피쳐의 $V \leq 0.35$ — 어떤 피쳐도 타겟을 강하게 결정하지 못함.
ML 모델 F1-macro 5~22%는 모델 문제가 아니라 피쳐셋 자체의 정보 부족.

② 피쳐 중요도 순위

성별 > 대업종 > 근무기간 > 연령 > 규모 > 건설공사금액 > 지역 > 년도