

학습 전 데이터 전처리 개요

모델 구조

업종 규모에 따라 대규모 5개는 개별 모델, 소규모 5개는 통합 1개 모델 (총 6개 모델). 타겟 폴더 2개:

폴더	대상 행	타겟 컬럼
target-발생 형태 /	전체 (분류불능 제외)	발생형태_enc, 재해정도_enc
target-질병 종류 /	발생형태 == 업무 상질병 행만	질병종류_enc, 세부질병종류_enc, 재해정도_enc

피처 (공통)

컬럼	타입	인코딩	비고
통계기준년월	수치형	int 그대로	
규모_enc	순서형	SIZE_ORDER (0~8)	
연령_enc	순서형	AGE_ORDER (0~9)	
근무기간_enc	순서형	WORK_PERIOD_ORDER (0~7)	
건설공사금액_enc	순서	CONST_AMT_ORDER (0~7)	건설업.csv에만 포함

컬럼	타입	인코딩	비고
	형		
성별_남	원 하	0/1	성별_여 드롭 (reference)
지역_강원 ~ 지역_충남	원 하	0/1 × 15개	지역_충북 드롭 (reference)

추가 피처 (소규모통합.csv 전용)

컬럼	타입	비고
산업_농업, 산업_어업, 산업_임업, 산업_전기가스	원하 0/1 × 4개	산업_금융 드롭 (reference, 0000=금융)

피처 컬럼 수 요약

파일	피처 수	총 컬럼 수 (발생 형태)	총 컬럼 수 (질병 종류)
건설업.csv	21	23	24
광업·기타·운수·제조 업.csv	20	22	23
소규모통합.csv	24	26	27

원하 인코딩 reference category 정리

그룹	드롭 (reference)	유지
성별	성별_여	성별_남 (1개)
지역	지역_충북	지역_강원~지역_충남 (15개)
산업	산업_금융	산업_농업·어업·임업·전기가스 (4개)

트리 기반 모델(LightGBM)에서 다중공선성은 성능에 영향 없으나, 선형 모델과의 일관성 및 피처 해석 명확성을 위해 reference category를 드롭함.

타겟 변수 인코딩

컬럼	타입	인코딩	클래스 수
발생형태_enc	명목형	ACCIDENT_TYPE_MAP (0~22)	23개
재해정도_enc	순서형	INJURY_ORDER (0~7)	8개
질병종류_enc	명목형	DISEASE_MAP (0~8)	9개
세부질병종류_enc	명목형	DISEASE_DETAIL_MAP (0~31)	32개

Train / Test Split 기준

구분	연도	행수 (발생형태 기준)
Train	2017~2023	약 796,524행 (73%)
Test	2024~2025	약 288,962행 (27%)

시계열 split — 데이터 누수 없음. 통계 기준년월 <= 2023 / >= 2024 로 분리.

분류불능 Drop 통계 (업종별)

대규모 업종

업종	원본	연령·근무기간 drop	발생형태 drop	건설공사금액 drop	발생형태 최종	질병종류 최종
건설업	271,290	25	139	3,343	267,808	41,688

업종	원본	연령· 근무기간 drop	발생 형태 drop	건설공사금액 drop	발생형태 최종	질병종류 최종
광업	24,856	112	32	0	24,824	23,545
기타의 사업	404,384	102	58	0	404,326	43,488
운수· 창고· 통신업	95,108	10	38	0	95,070	7,194
제조업	272,567	75	74	0	272,493	60,941

소규모 업종 (통합)

업종	원본	drop	발생형태 최종	질병종류 최종
농업	6,038	1	6,037	366
어업	505	1	504	39
임업	9,055	0	9,055	482
전기·가스·증기·수도사업	1,033	4	1,029	197
금융및보험업	4,340	0	4,340	796
소규모 합계	20,971	6	20,965	1,880

전체 합계

	원본	총 drop	발생형태 최종	질병종류 최종
합계	1,089,532	4,046	1,085,486	178,736

전체 drop: 4,046행 (원본의 0.37%), 보존율 99.63%

파일 구조

```
학습전데이터/
├─ kosha_encodings.py      전역 인코딩 dict (순서형 피처)
├─ preprocess.py          전처리 통합 스크립트 (1·2단계 포함)
├─ 개요.md                이 파일
├─ target-발생형태/
│   ├─ 건설업.csv         267,808행 피처 23개
│   ├─ 광업.csv           24,824행 피처 22개
│   ├─ 기타의사업.csv     404,326행 피처 22개
│   ├─ 운수_창고_통신업.csv 95,070행 피처 22개
│   ├─ 제조업.csv         272,493행 피처 22개
│   └─ 소규모통합.csv     20,965행 피처 26개 (산업 원핫 포함)
└─ target-질병종류/
    ├─ 건설업.csv         41,688행 피처 24개
    ├─ 광업.csv           23,545행 피처 23개
    ├─ 기타의사업.csv     43,488행 피처 23개
    ├─ 운수_창고_통신업.csv 7,194행 피처 23개
    ├─ 제조업.csv         60,941행 피처 23개
    └─ 소규모통합.csv     1,880행 피처 27개 (산업 원핫 포함)
```