

학습 전 데이터 전처리 개요

피처 구성 및 인코딩 방식

모델 구조

업종 규모에 따라 대규모 5개는 개별 모델, 소규모 5개는 통합 1개 모델 (총 6개 모델)

폴더	대상 행	타겟 컬럼
target-발생형태/	전체 (분류불능 제외)	발생형태_enc, 재해정도_enc
target-질병종류/	발생형태 == 업무상질병 행만	질병종류_enc, 세부질병종류_enc, 재해정도_enc

피처 (공통)

컬럼	타입	인코딩	비고
통계기준년월	수치형	int 그대로	
규모_enc	순서형	SIZE_ORDER (0~8)	
연령_enc	순서형	AGE_ORDER (0~9)	
근무기간_enc	순서형	WORK_PERIOD_ORDER (0~7)	
종업종_enc	명목형	SUBJOB_MAP (0~43)	SUBJOB_NORM 82→44 통합, categorical_feature
건설공사금액_enc	순서형	CONST_AMT_ORDER (0~7)	건설업.csv 전용
성별_남	원핫	0/1	성별_여 드롭 (reference)
지역_강원 ~ 지역_충남	원핫	0/1 × 15개	지역_충북 드롭 (reference)

추가 피처 (소규모통합.csv 전용)

컬럼	비고
산업_농업, 산업_어업, 산업_임업, 산업_전기가스 (0/1 × 4개)	산업_금융 드롭 (reference, 0000 = 금융)

피처 컬럼 수 요약

파일	피처 수	총 컬럼 수 (발생형태)	총 컬럼 수 (질병종류)
건설업.csv	22	24	25
광업·기타·운수·제조업.csv	21	23	24
소규모통합.csv	25	27	28

원핫 인코딩 Reference Category

그룹	드롭 (reference)	유지
성별	성별_여	성별_남 (1개)
지역	지역_충북	지역_강원 ~ 지역_충남 (15개)
산업	산업_금융	산업_농업·어업·임업·전기가스 (4개)

* 트리 기반 모델(LightGBM)에서 다중공선성은 성능에 영향 없으나, 피처 해석 명확성을 위해 reference category 드롭.

Train / Test Split 기준

구분	연도	행수 (발생형태 기준)
Train	2017~2023	약 796,524행 (73%)
Test	2024~2025	약 288,962행 (27%)

* 시계열 split — 데이터 누수 없음. 통계기준년월 <= 2023 / >= 2024 로 분리.

종업종 정규화 · 타겟 인코딩 · Drop 통계

종업종 정규화 (SUBJOB_NORM)

KOSHA는 연도별로 종업종 분류 기준을 여러 차례 변경 → 동일 업종이 최대 5가지 다른 이름으로 기록됨.
kosha_encodings.py의 SUBJOB_NORM이 82개 원본 → 44개 통합 명칭으로 정규화, SUBJOB_MAP이 정수(0~43)로 인코딩.

단계	처리	예시
1단계 (SUBJOB_NORM)	82개 원본 표기 → 44개 통합	기계기구·비금속·금속제조업 등 5종 → 기계기구·금속·비금속광물제품제조업
2단계 (SUBJOB_MAP)	44개 통합명 → 정수	기계기구·금속·비금속광물제품제조업 → 7

* LightGBM 학습 시 categorical_feature=['종업종_enc'], max_cat_threshold=64 설정으로 명목형 분기 처리.

타겟 변수 인코딩

컬럼	타입	인코딩	클래스 수
발생형태_enc	명목형	ACCIDENT_TYPE_MAP (0~22)	23개
재해정도_enc	순서형	INJURY_ORDER (0~7)	8개
질병종류_enc	명목형	DISEASE_MAP (0~8)	9개
세부질병종류_enc	명목형	DISEASE_DETAIL_MAP (0~31)	32개

분류불능 Drop 통계 — 대규모 업종

공통 drop 조건: 연령_enc == -1 OR 근무기간_enc == -1 OR 종업종_enc is NaN

업종	원본	공통 drop	발생형태 drop	건설공사금액 drop	발생형태 최종	질병종류 최종
건설업	271,290	25	139	3,343	267,808	41,688
광업	24,856	112	32	0	24,824	23,545
기타의사업	404,384	102	58	0	404,326	43,488
운수·창고·통신업	95,108	10	38	0	95,070	7,194
제조업	272,567	75	74	0	272,493	60,941

분류불능 Drop 통계 — 소규모 업종 (통합)

업종	원본	drop	발생형태 최종	질병종류 최종
농업	6,038	1	6,037	366
어업	505	1	504	39
임업	9,055	0	9,055	482
전기·가스·증기·수도사업	1,033	4	1,029	197
금융및보험업	4,340	0	4,340	796
소규모 합계	20,971	6	20,965	1,880

전체 합계

원본	총 drop	발생형태 최종	질병종류 최종
1,089,532	4,046	1,085,486	178,736

* 전체 drop: 4,046행 (원본의 0.37%), 보존율 99.63%

학습전데이터/ 디렉토리 구조

학습전데이터/		
├──	kosha_encodings.py	전역 인코딩 dict (순서형·명목형 피처, 역매핑 *_INV 포함)
├──	preprocess.py	전처리 통합 스크립트 (1·2단계 포함)
├──	개요.md	이 파일
├──	target-발생형태/	
	├── 건설업.csv	267,808행 피처 24개
	├── 광업.csv	24,824행 피처 23개
	├── 기타의사업.csv	404,326행 피처 23개
	├── 운수_창고_통신업.csv	95,070행 피처 23개
	├── 제조업.csv	272,493행 피처 23개
	└── 소규모통합.csv	20,965행 피처 27개 (산업 원핫 포함)
└──	target-질병종류/	
	├── 건설업.csv	41,688행 피처 25개
	├── 광업.csv	23,545행 피처 24개
	├── 기타의사업.csv	43,488행 피처 24개
	├── 운수_창고_통신업.csv	7,194행 피처 24개
	├── 제조업.csv	60,941행 피처 24개
	└── 소규모통합.csv	1,880행 피처 28개 (산업 원핫 포함)